BOTTLENECK

Analyse des Ventes et des Stocks — Site Web

Fichiers : ERP · Web · Liaison

Projet 6 — OpenClassrooms · Analyste de Données

01 — Contexte & Sources de données

Bottleneck est un marchand de vins en ligne. L'objectif de cette mission est d'analyser les ventes et les stocks à partir de l'extraction du 31 octobre 2024, afin de fournir un reporting fiable à la direction.

ERP.xlsx

Source interne

Prix de vente, prix d'achat, stock, statut web

462 produits

WEB.xlsx

Site e-commerce

Ventes, noms des vins, type de produit, TVA

714 lignes brutes

LIAISON.xlsx

Table de correspondance

Fait le pont entre les références ERP et Web

500 associations

01 — Contexte & Sources de données

Bottleneck est un marchand de vins en ligne. L'objectif de cette mission est d'analyser les ventes et les stocks à partir de l'extraction du 31 octobre 2024, afin de fournir un reporting fiable à la direction.

ERP.xlsx

Source interne

825 observations
6 colonnes

Données :

- product_id
- price
- stock_quantity
- stock_status
- (instock / outofstock)

WEB.xlsx

Site e-commerce

1513 observations
29 colonnes

Données :

- sku
- total_sales
- tax_status (taxable)
- product_type (vin, gin, whisky…)

LIAISON.xlsx

Table de correspondance

825 observations
2 colonnes

Données :

- id_web (734valeurs)
- product_id

02 — Nettoyage & Qualité des données

Audit

Comprendreavant d'agir

Nettoyage

- Nettoyage structurel - Gestion valeurs manquantes - Traitement outliers - Feature engineering

Validation

Vérification post-fusion

Dataset prêt

Traçabilité & reproductibilité

02 — Nettoyage & Qualité des données

Avant toute analyse, j'ai audité les 3 fichiers. J'ai trouvé et corrigé 8 anomalies qui auraient faussé tous les résultats.

Anomalie détectée	Fichier	Action corrective
Stock négatif (quantités < 0)	ERP	Remplacé par 0 — le stock ne peut pas être négatif
stock_status incohérent avec le stock réel	ERP	Recalculé via lambda : instock / outofstock
Prix nuls ou négatifs (price ≤ 0)	ERP	Supprimé — produit inexploitable sans prix
SKU atypiques : 13127-1, bon-cadeau-25-euros	Web	Vérifiés dans liaison — conservés car valides
Lignes sans SKU (NaN)	Web	Supprimées — impossible de relier à l'ERP
Lignes non-produits (post_type ≠ product)	Web	Filtrées — on ne garde que les vrais produits
Doublons de SKU dans Web	Web	Dédoublonnés — keep='first'
91 produits ERP absents du site Web	Liaison	Écartés de l'analyse — aucune vente en ligne

Produits Fantômes — En ligne sans stock

Produits affichés en vente sur le site (onsale_web = 1) mais avec un stock réel ≤ 0. Un client peut commander... mais la bouteille n'existe pas.

Le problème

Le stock_status indique 'instock' dans l'ERP mais la quantité réelle est 0 ou négative. L'ERP et le site Web sont désynchronisés.

Ce que j'ai fait

J'ai recalculé le stock_status via une fonction lambda : si stock_quantity ≤ 0 → outofstock, sinon → instock. Puis comparé colonne à colonne.

Action corrective

Remplacement des valeurs incohérentes. Les stocks négatifs ont été remis à 0. Le statut Web doit être mis à jour automatiquement depuis l'ERP.

💡 Recommandation : Mettre en place une synchronisation automatique ERP → Site Web pour éviter la vente de produits inexistants.

Définition des termes importants

Le Z-Score

Définition

Le Z-score mesure l'écart entre un prix et la moyenne du catalogue, exprimé en nombre d'écarts-types.

La formule : Z = (prix − moyenne) / écart-type.

J'ai retenu le seuil de 3 — convention statistique universelle : au-delà, le produit est dans le top 0,15% des valeurs les plus extrêmes.
Une frontière objective basée sur les données, pas sur l'intuition justifiés.

L'Intervalle Interquartile (IQR)

Définition

L'IQR mesure la zone de prix "normale" du catalogue en se basant sur les 50% du milieu. La formule : IQR = Q3 − Q1. Tout ce qui dépasse Q3 + 1,5 × IQR est un outlier.

Son avantage sur le Z-score : il ne se laisse pas influencer par les valeurs extrêmes elles-mêmes, ce qui le rend plus robuste.

Les deux méthodes ont convergé vers les mêmes produits — résultats confirmé

RGPD

Définition

Le Règlement Général sur la Protection des Données encadre l'utilisation des données personnelles en Europe depuis 2018.

Dans ce projet, les fichiers ne contiennent aucune donnée personnelle — uniquement des références produits, des prix et des stocks. Aucun risque d'exposition de données clients.

03 — Analyse des prix : Détection d'outliers

J'ai utilisé deux méthodes statistiques pour détecter les prix atypiques dans le catalogue final.

Méthode 1 — Z-Score

Principe : Mesure l'écart de chaque prix par rapport à la moyenne, en unités d'écart-type.

Seuil retenu : Z-Score > 3

~15	~2%	~6%
outliers détectés	du catalogue	du CA total

➡ *Ces bouteilles à 150-300€ sont des Grands Crus — pas des erreurs informatiques. Leur prix élevé est justifié commercialement.*

Méthode 2 — IQR (Intervalle Interquartile)

Principe : Délimite une zone 'normale' à partir des quartiles Q1 et Q3. Tout ce qui dépasse est outlier.

Borne haute : *Q3 + 1,5 × IQR*

Résultat : Les deux méthodes identifient les mêmes produits. La convergence des méthodes confirme que ces outliers sont réels.

⚠️ **Alerte Egly-Ouriet (Champagne)**

Vendu 11€ · Acheté 66€ → Marge de -86% · Perte de 66€ par bouteille vendue → Erreur de saisie à corriger en urgence.

04 — Analyse des ventes & Règle 20/80

143 680 €

CA Total du site web

~20%

des produits génèrent 80% du CA

~20%

des produits génèrent 80% des ventes en quantité

Segmentation du catalogue :

STARS

Dans le Top CA ET le Top Quantité.
Gros volume + bon prix = gros CA.
Ex : Mas Laval IGP Pampres Blancs 2018
→ Produit locomotive de Bottleneck.

LUXE

Dans le Top CA mais pas le Top Quantité.
Prix élevé, peu d'exemplaires vendus.
Ex : Grands Crus, Champagnes de prestige
→ Contribuent à 6% du CA à eux seuls.

APPEL

Dans le Top Quantité mais pas le Top CA.
Prix faible, fort volume de ventes.
Vins d'entrée de gamme qui attirent le client et font tourner la logistique.

Si la proportion en quantité est plus faible que celle du CA (ex: 12% contre 18%) : Cela signifie qu'une toute petite poignée de produits génère l'essentiel du travail de préparation de commande. C'est ce qu'on appelle des produits "à haute rotation".

Manque à Gagner — 91 Produits Hors Ligne

91 références sont dans l'ERP mais absentes du site Web. Aucune vente possible en ligne pour ces produits.

91	0 €	Moyenne des ventes par produit : 8.05 unités Manque à gagner estimé : 28 237.09 €
produits ERP hors ligne	CA généré par ces produits	

Pourquoi je les ai écartés de l'analyse :

1. Ces produits n'ont pas de SKU Web — impossible de calculer leur CA ou leurs ventes en ligne.
2. Les inclure forcerait des ventes à 0€ et fausserait la moyenne de CA par produit.
3. Il peut s'agir de cuvées spéciales, vieux millésimes ou échantillons stockés mais jamais mis en vente.

💡 Action : Vérifier avec l'équipe commerciale si ces 91 produits peuvent être mis en ligne — chaque référence est un CA potentiel inexploité.

05 — Stocks & Taux de marge

Analyse des Stocks

Indice de rotation global **0,34**

Pour 1 bouteille vendue, 3 dorment en stock

Valeur totale du stock **277 328.07 €**

Capital immobilisé > CA — trésorerie bloquée

Taux de Marge par Catégorie

Formule utilisée : *Taux de marge = (Prix HT − Prix d'achat) / Prix d'achat × 100*
Avec Prix HT = Prix TTC / 1,20 (TVA 20%)

Performance : Le taux de marge moyen sain du catalogue s'établit à 61.22%, avec des pics à 91% sur les produits stars.

Mois de stock sur certains produits **100+**

À ce rythme, des années pour vider le stock

⚠️ **Egly-Ouriet : marge de −86% → erreur de saisie à corriger en urgence**

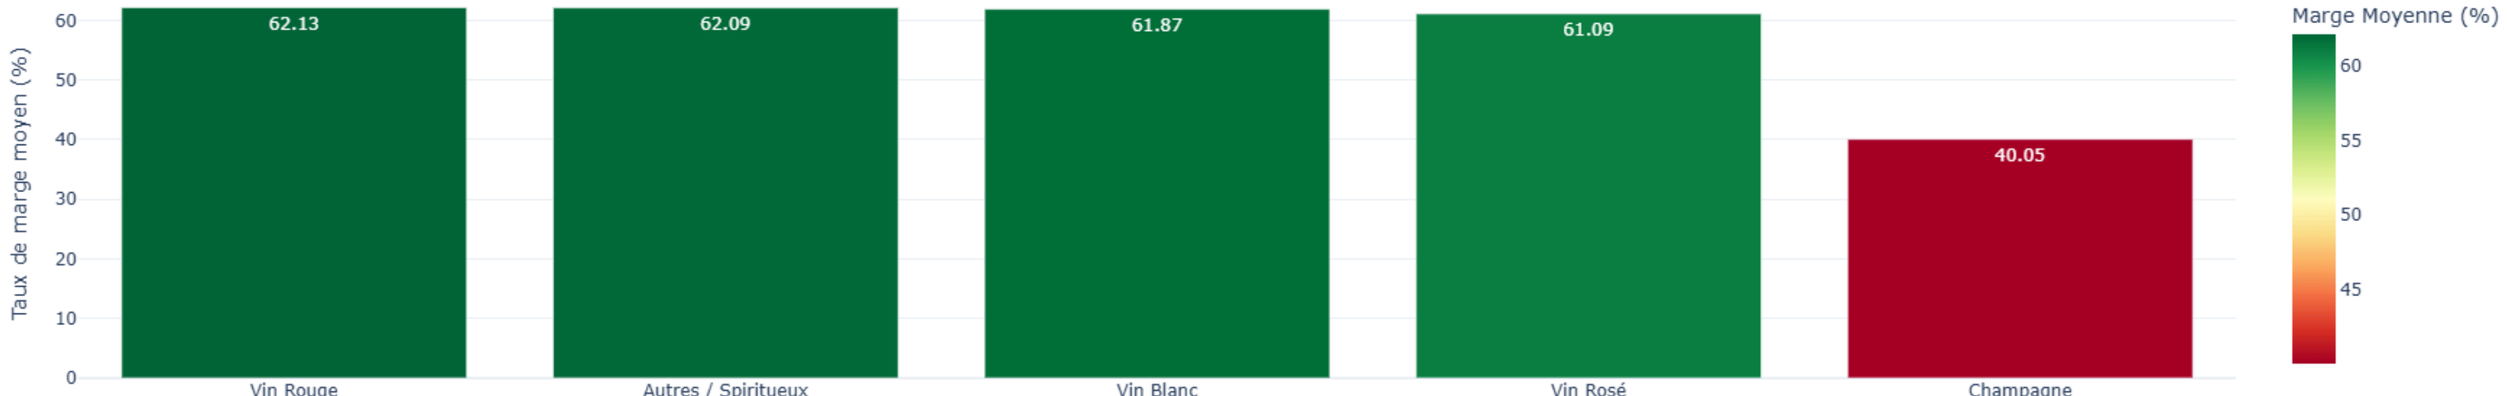

Stock vs CA — La Trésorerie Bloquée

Comparer la valeur du stock au CA permet de savoir si l'entreprise stocke trop par rapport à ce qu'elle vend.

143 680 €

CA Total du site web

Ce que Bottleneck a encaissé sur la période d'octobre.

> CA

Valeur du Stock (achat)

Capital immobilisé dans les bouteilles en entrepôt.

Ce que ça signifie :

Trésorerie bloquée : L'argent de Bottleneck est bloque dans les cartons plutot que de circuler en tresorerie.

Rotation faible (0,34) : Pour 1 bouteille vendue, 3 dorment. Il faudrait des années pour vider le stock au rythme actuel.

Risque qualité : Pour du vin, un stock qui ne tourne pas peut se détériorer (conditions de conservation sur le long terme).

Taux de Marge — Synthèse Complète

Calculé sur le dataset nettoyé (df_cleaned), hors produits avec marge négative (Egly-Ouriet).

61,22%	91%	−86%
Taux de marge moyen sain	Pic sur les produits Stars	Egly-Ouriet (erreur à corriger)

Formule : Taux de marge = (Prix HT − Prix d'achat) / Prix d'achat × 100 | Prix HT = Prix TTC / 1,20

Points clés :

- La TVA (20%) est déduite avant tout calcul — elle appartient à l'État, pas à Bottleneck.
- Les Vins Rouges et Blancs ont les meilleures marges (>48%). Ce sont les catégories à promouvoir en priorité.
- Un taux de 61% est sain. Cela signifie que pour 100€ de vin vendu HT, 61€ sont de la marge brute.
- Les produits Stars atteignent 91% de marge — ce sont les vrais moteurs de rentabilité du catalogue.

Alerte Qualité — Risque de Péremption du Stock

Un stock qui ne tourne pas est un risque commercial ET qualitatif pour un marchand de vins.

⚠️ **Certains produits affichent 100+ mois de stock — soit plus de 8 ans au rythme actuel des ventes.**

🍷 Qualité du vin

Un vin mal stocké ou conservé trop longtemps perd ses qualités organoleptiques. Cela nuit à la réputation de Bottleneck si le client reçoit une bouteille oxydée ou bouchonnée.

💰 Capital immobilisé

Chaque bouteille en stock représente de l'argent qui ne circule pas. Un stock de 100+ mois signifie que certains achats fournisseurs ne seront jamais rentabilisés avant des années.

📉 Démarque inconnue

Plus le stock vieillit, plus le risque de devoir solder à prix cassé augmente. Ce qui était une bonne marge devient une perte si le

💡 **Action prioritaire : Identifier les 20 produits avec le plus de mois de stock et lancer des promotions ciblées avant détérioration.**

06 — Corrélations entre les variables clés

J'ai analysé les corrélations entre prix, ventes, stocks et prix d'achat sur le dataset nettoyé (df_cleaned).

+0,99

Prix de vente / Prix d'achat

Normale

Corrélation quasi-totale : les fournisseurs fixent le prix de vente. Très peu de marge de négociation possible.

-0,52

Prix de vente / Quantités vendues

A surveiller

Corrélation négative modérée : plus une bouteille est chère, moins elle se vend. Loi de l'offre et de la demande.

+0,44

Stock / Quantités vendues

Bonne gestion

Les produits les plus vendus ont aussi plus de stock — Bottleneck anticipe bien la demande sur ses bestsellers.

-0,09

Stock / Prix de vente

Neutre

Quasi-nulle : le niveau de stock n'est pas lié au prix. Les décisions de stockage semblent indépendantes du prix.

Corrélation Prix / Ventes — Marché Concurrentiel

Coefficient de corrélation : −0,52 → corrélation négative modérée entre le prix et les quantités vendues.

Ce que −0,52 signifie concrètement :

Plus le prix d'une bouteille augmente, moins elle se vend en volume. C'est la loi classique de l'offre et de la demande. Avec −0,52, la relation est réelle mais pas absolue : il existe des exceptions (les Grands Crus se vendent peu mais restent désirables).

Implications stratégiques pour Bottleneck :

Sensibilité au prix élevée

Toute hausse de prix doit être justifiée (millésime, médaille, mise en avant). Le client Bottleneck est price-sensitive.

Stratégie volume

Pour maximiser les ventes en quantité, miser sur les vins d'entrée de gamme bien positionnés (< 15€).

Stratégie valeur

Pour le CA, ce sont les vins entre 30€ et 80€ (marge élevée + volume acceptable) qui sont le sweet spot.

Marché concurrentiel

Un −0,52 confirme que Bottleneck évolue dans un marché où le prix est un critère de décision fort pour l'acheteur en ligne.

06 — Recommandations stratégiques

URGENT — **Correction Egly-Ouriet**

Le Champagne Egly-Ouriet est vendu à perte (−86% de marge). Il faut corriger le prix d'achat ou le prix de vente immédiatement pour éviter une perte de 66€ par bouteille vendue.

MARKETING — **Booster les catégories à forte marge**

Les Vins Rouges et Blancs affichent les meilleures marges (>45%). Mettre en avant ces catégories dans les campagnes et la navigation du site pour maximiser la rentabilité.

STOCK — **Réduire le sur-stockage**

L'indice de rotation global est de 0,34. Pour chaque bouteille vendue, 3 dorment. Prioriser les promotions sur les produits avec 100+ mois de stock, notamment sur les vins à plus de 100€.

SYSTÈME — **Mettre en ligne les 91 produits hors ligne**

91 références ERP ne sont pas sur le site. Vérifier avec l'équipe commerciale s'il s'agit d'oublis — une mise en ligne pourrait représenter un manque à gagner significatif.

Préparation aux Questions — Nicolas / Jury

Réponses synthétiques aux questions attendues en discussion.

Q : Fiabilité des données — Écarter ou corriger ?

→ Les deux selon le cas. J'ai corrigé ce qui était récupérable (stocks négatifs → 0, stock_status incohérent). J'ai écarté ce qui était inexploitable (lignes sans SKU, produits sans prix). Chaque choix est justifié et tracé.

Q : Données manquantes — Éliminer ou renseigner ?

→ J'ai éliminé les lignes où la donnée manquante rendait le produit inexploitable (pas de SKU = pas de jointure possible). Pour les NaN sur des colonnes secondaires, j'ai remplacé par une valeur neutre (ex : 'Standard' pour la taxe).

Q : Valorisation des stocks — Votre avis ?

→ J'ai valorisé au prix d'achat — c'est la valeur comptable réelle. La valeur du stock dépasse le CA mensuel, ce qui signifie que la trésorerie est bloquée dans les bouteilles. L'indice de rotation de 0,34 confirme le sur-stockage.

Q : Conformité RGPD ?

→ Les fichiers analysés ne contiennent aucune donnée personnelle — uniquement des références produits, prix et stocks. Aucun risque d'exposition. Si des données clients avaient été présentes, j'aurais appliqué anonymisation et minimisation.

En résumé

Ce que ce projet m'a appris :

Un fichier de données n'est jamais parfait. La vraie valeur d'un analyste, c'est de détecter les erreurs avant qu'elles ne faussent les décisions.
Chaque anomalie corrigée ici représente une décision business plus fiable pour Bottleneck.

Pour la suite :

1. produits_hors_ligne_a_verifier.csv Liste des 91 produits ERP absents du site. Destiné à l'équipe commerciale pour décider lesquels mettre en ligne.
2. Reporting_Complet_BottleNeck.xlsx Le df_final complet — tous les produits nettoyés avec prix HT, CA et marges. Le reporting principal pour Nicolas.
3. Analyse_Detaillee_BottleNeck.xlsx 3 feuilles : Catalogue complet / Alertes à corriger (marges négatives) / Top 20 ventes. Pour une analyse plus fine par les équipes.

Merci — Je suis disponible pour vos questions

Bonus — Documentation

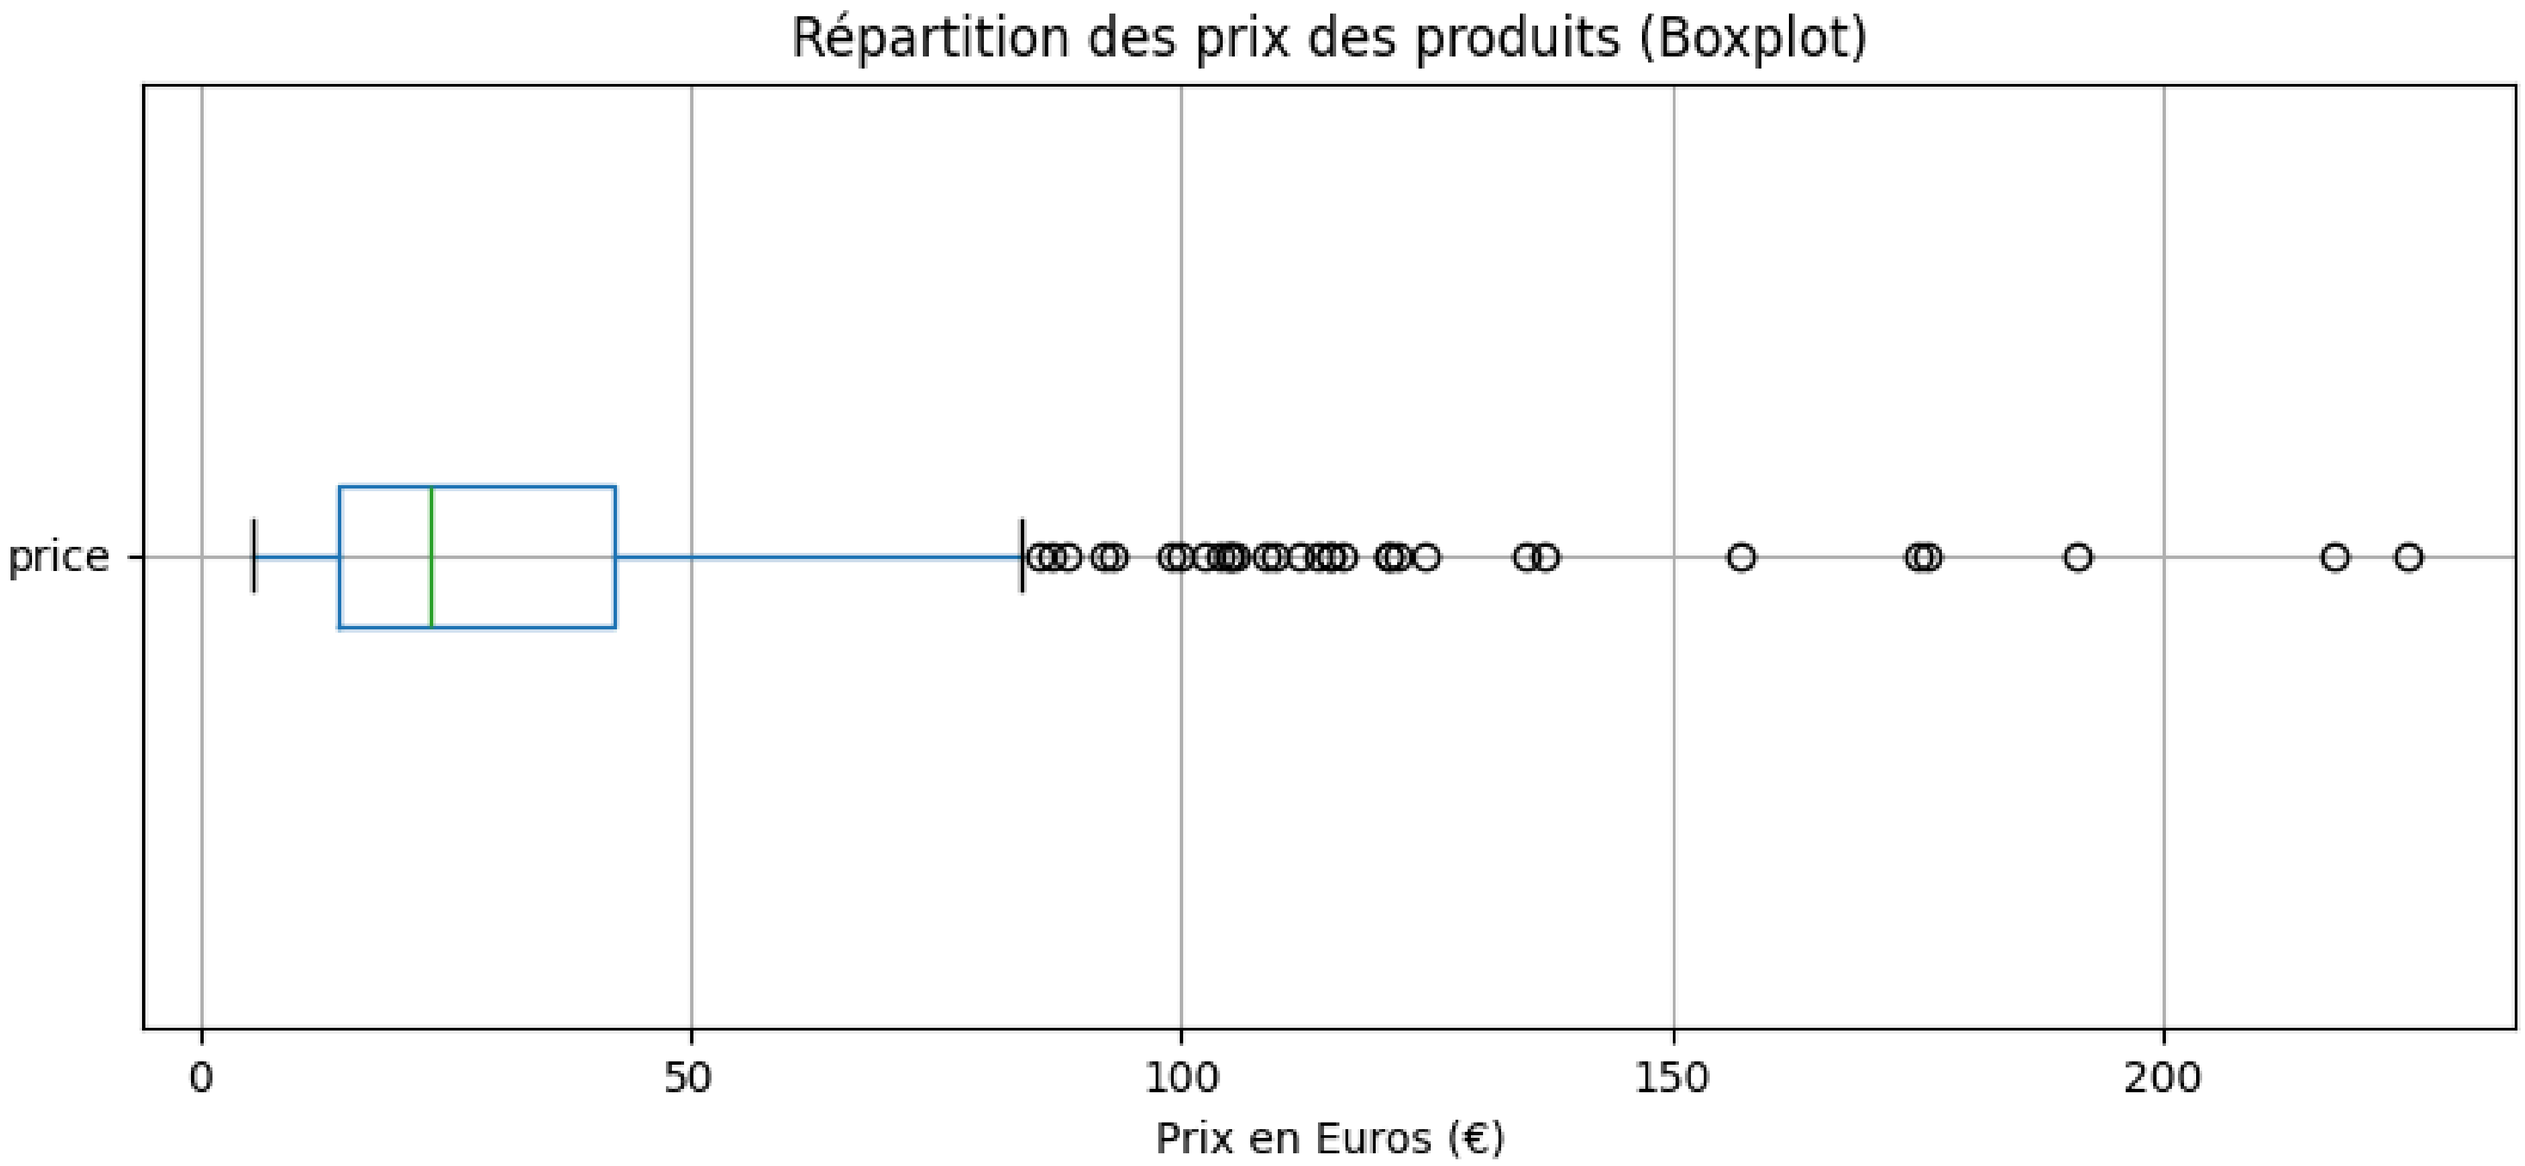

Bonus — Documentation

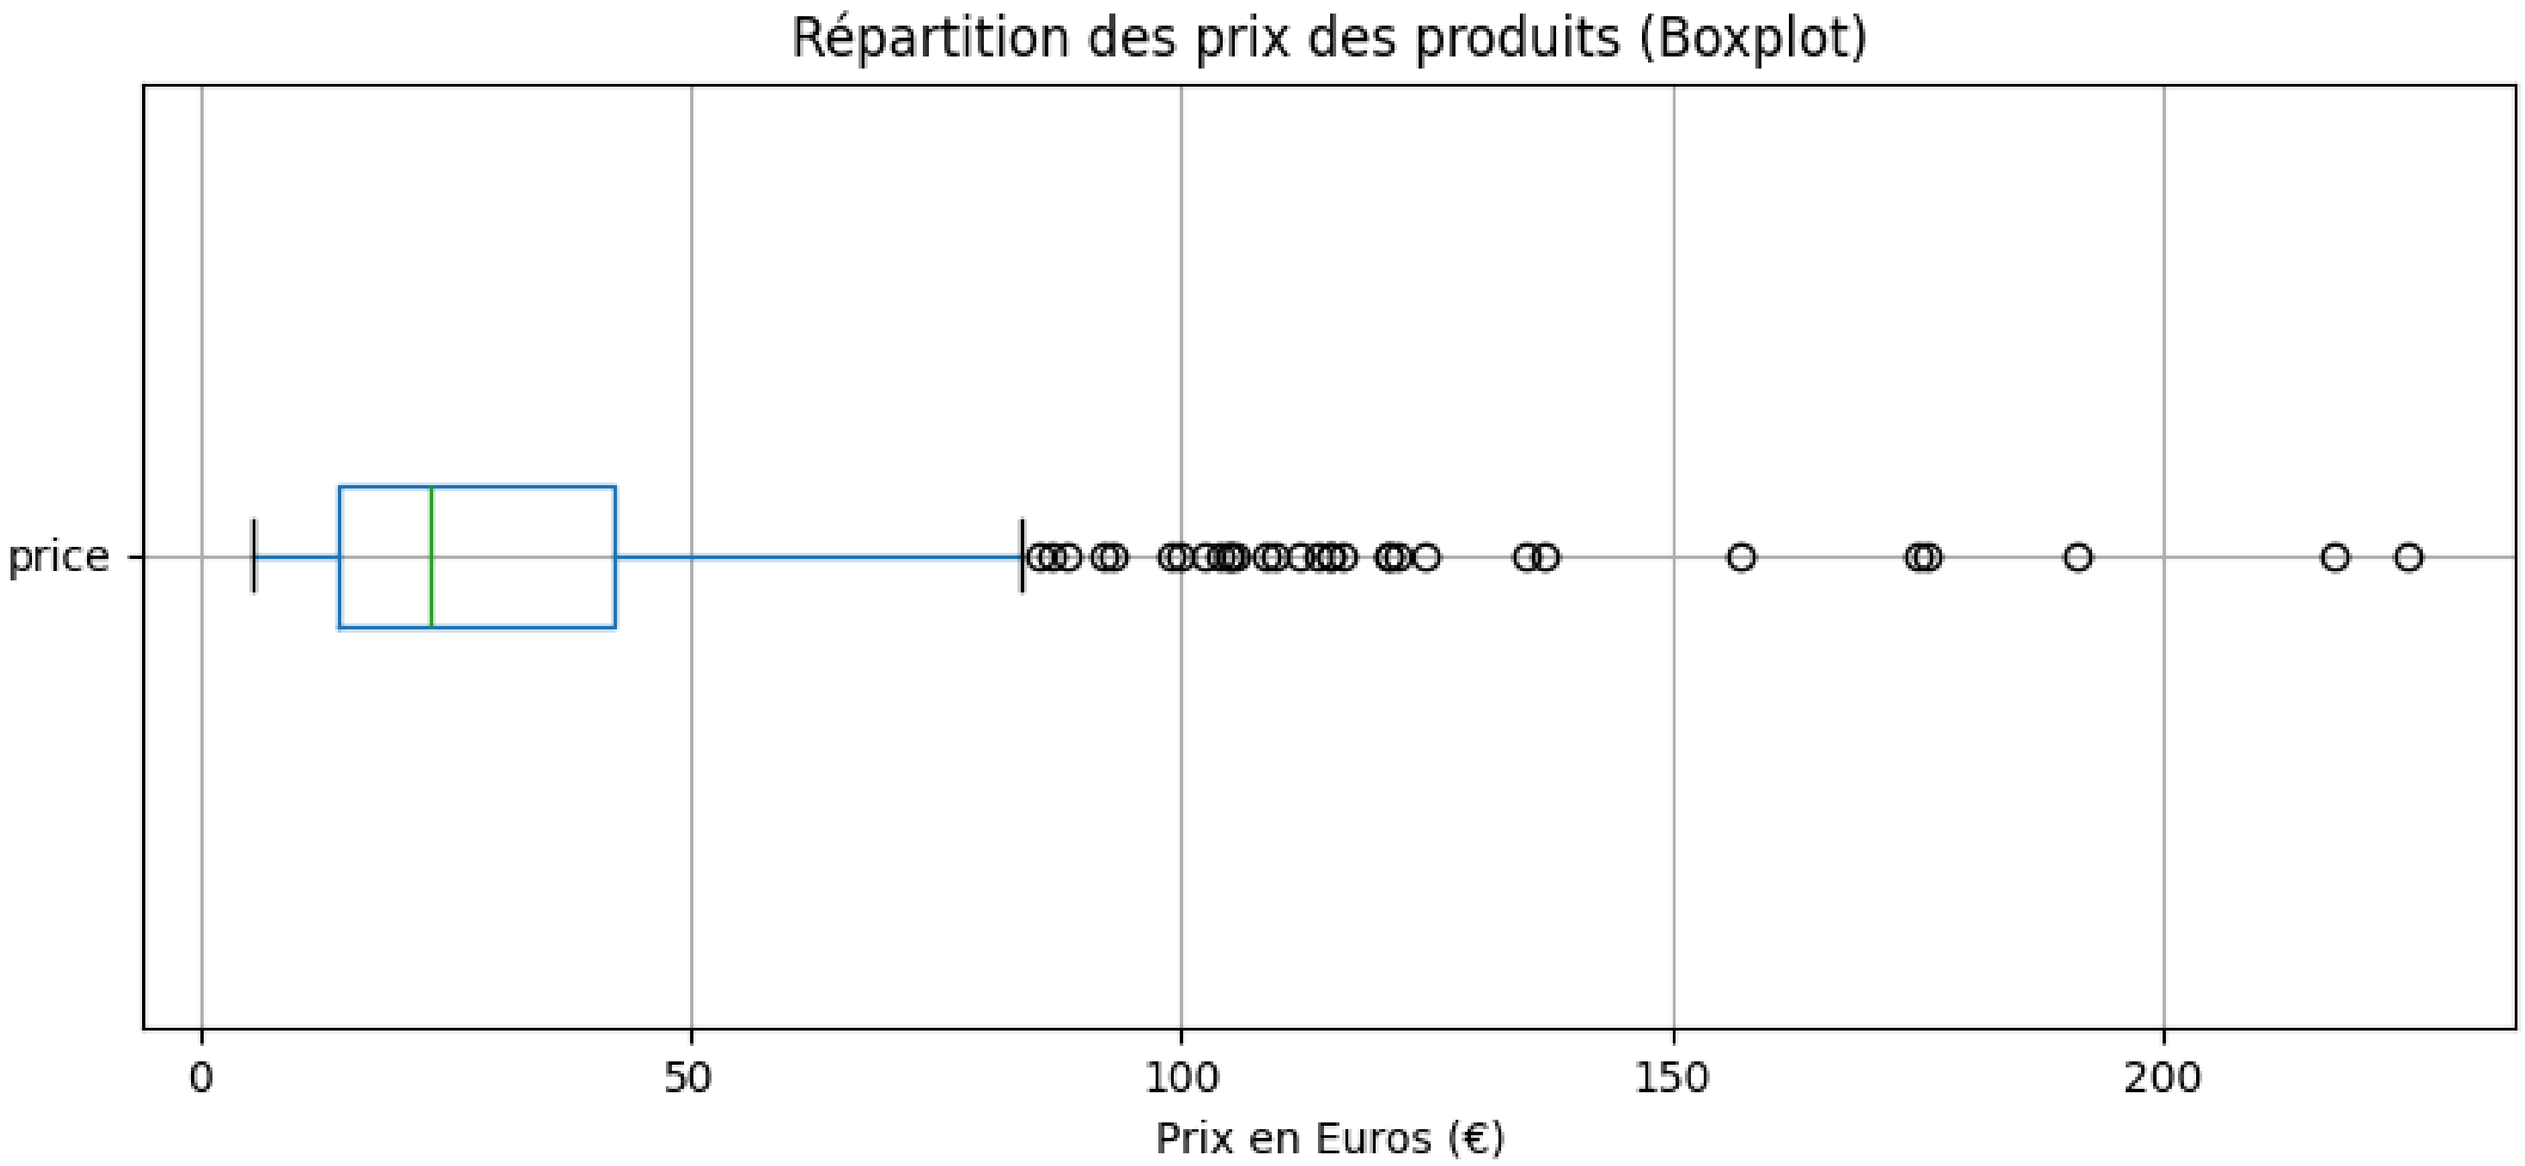

Bonus — Documentation

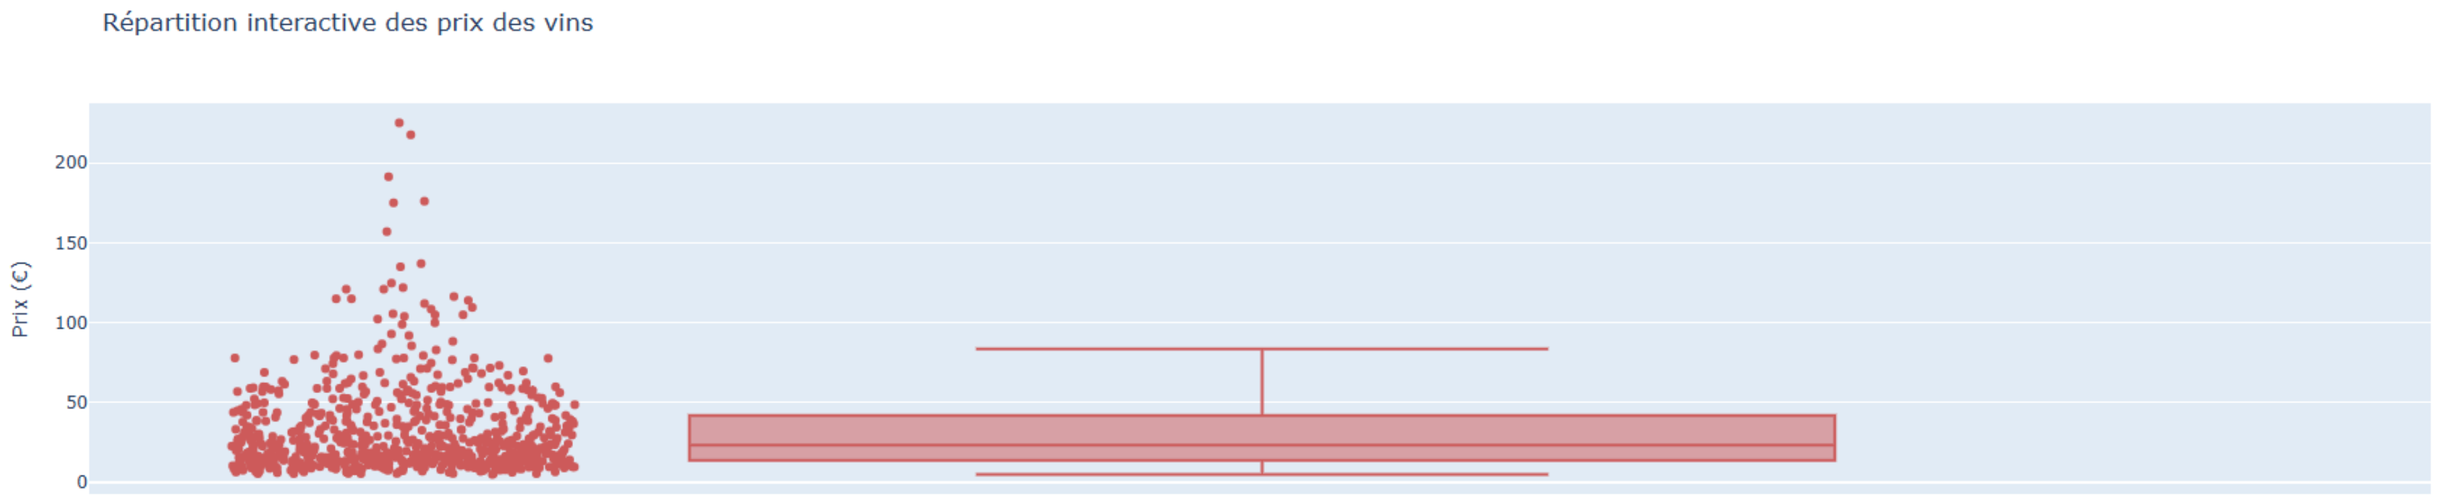

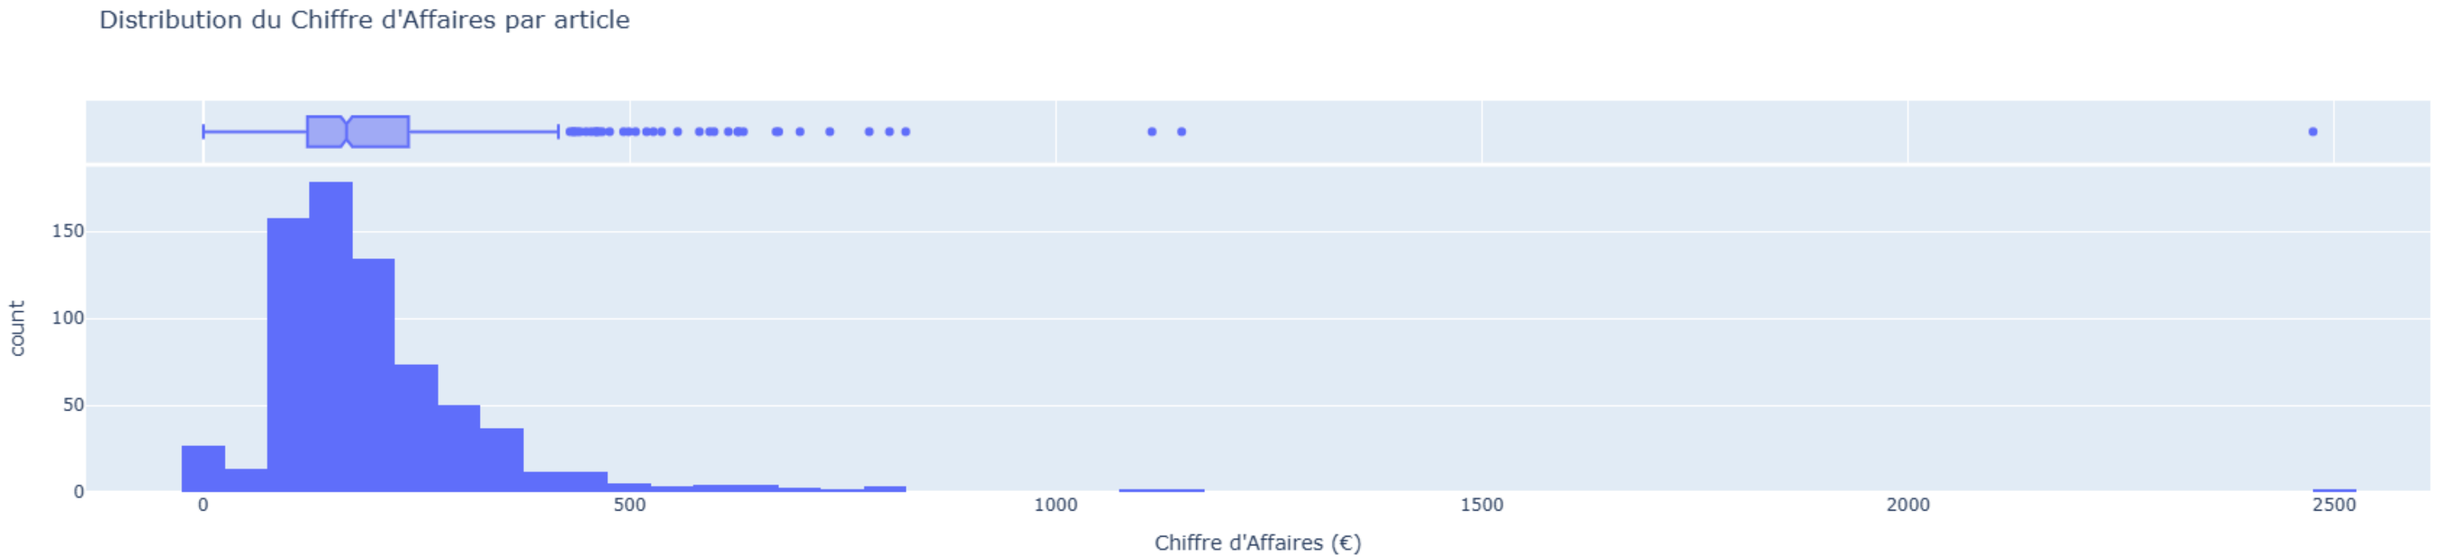

Bonus — Documentation

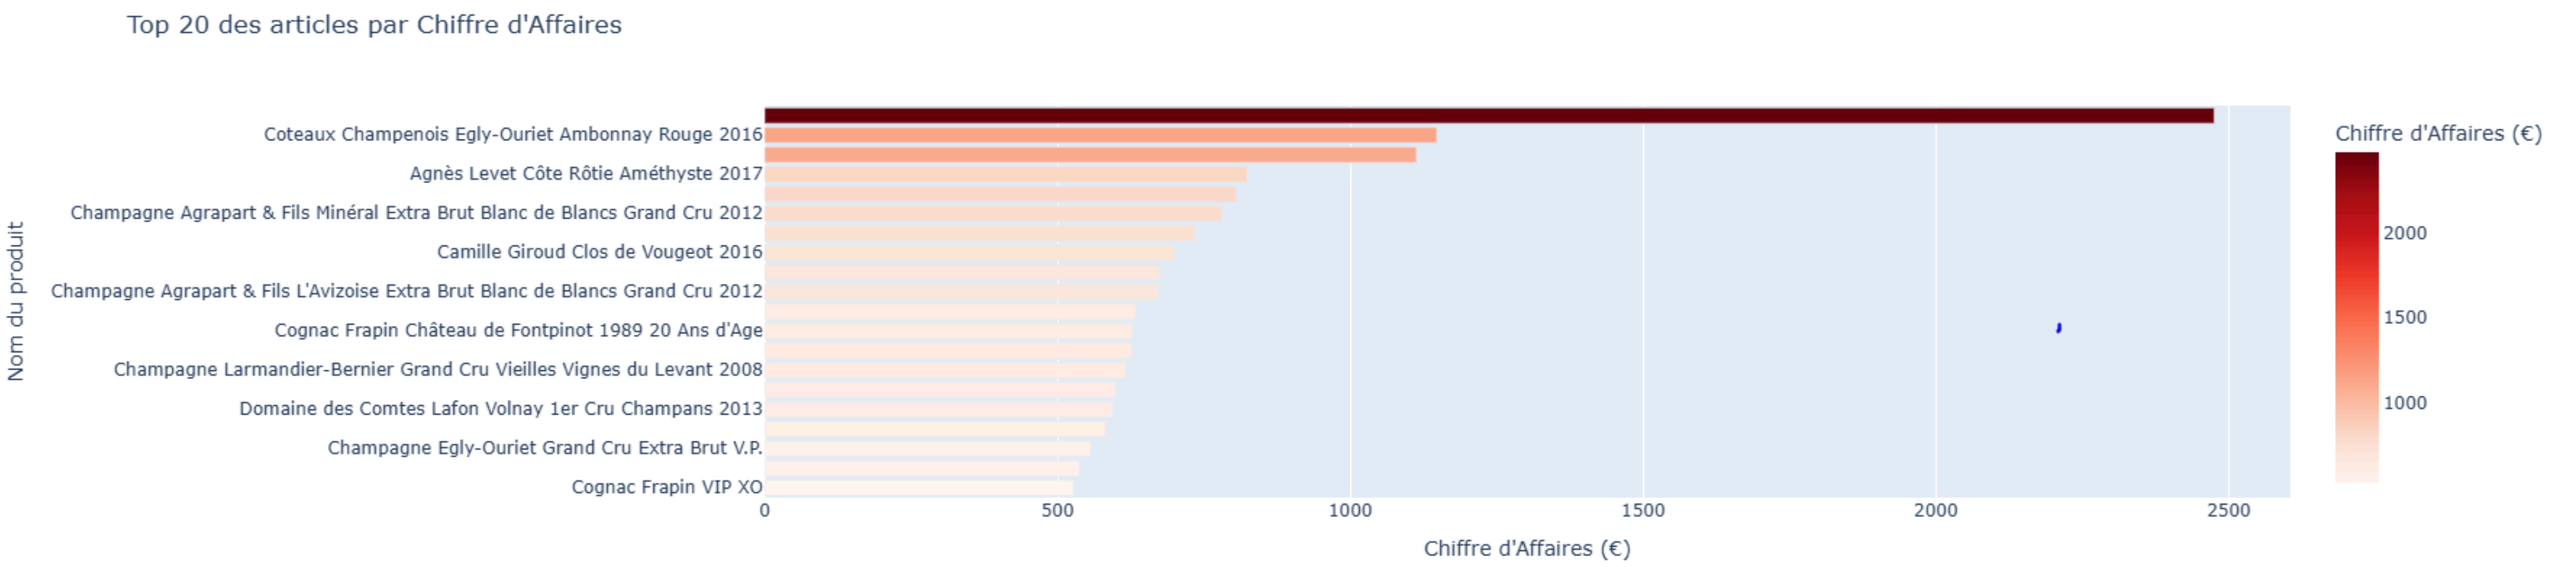

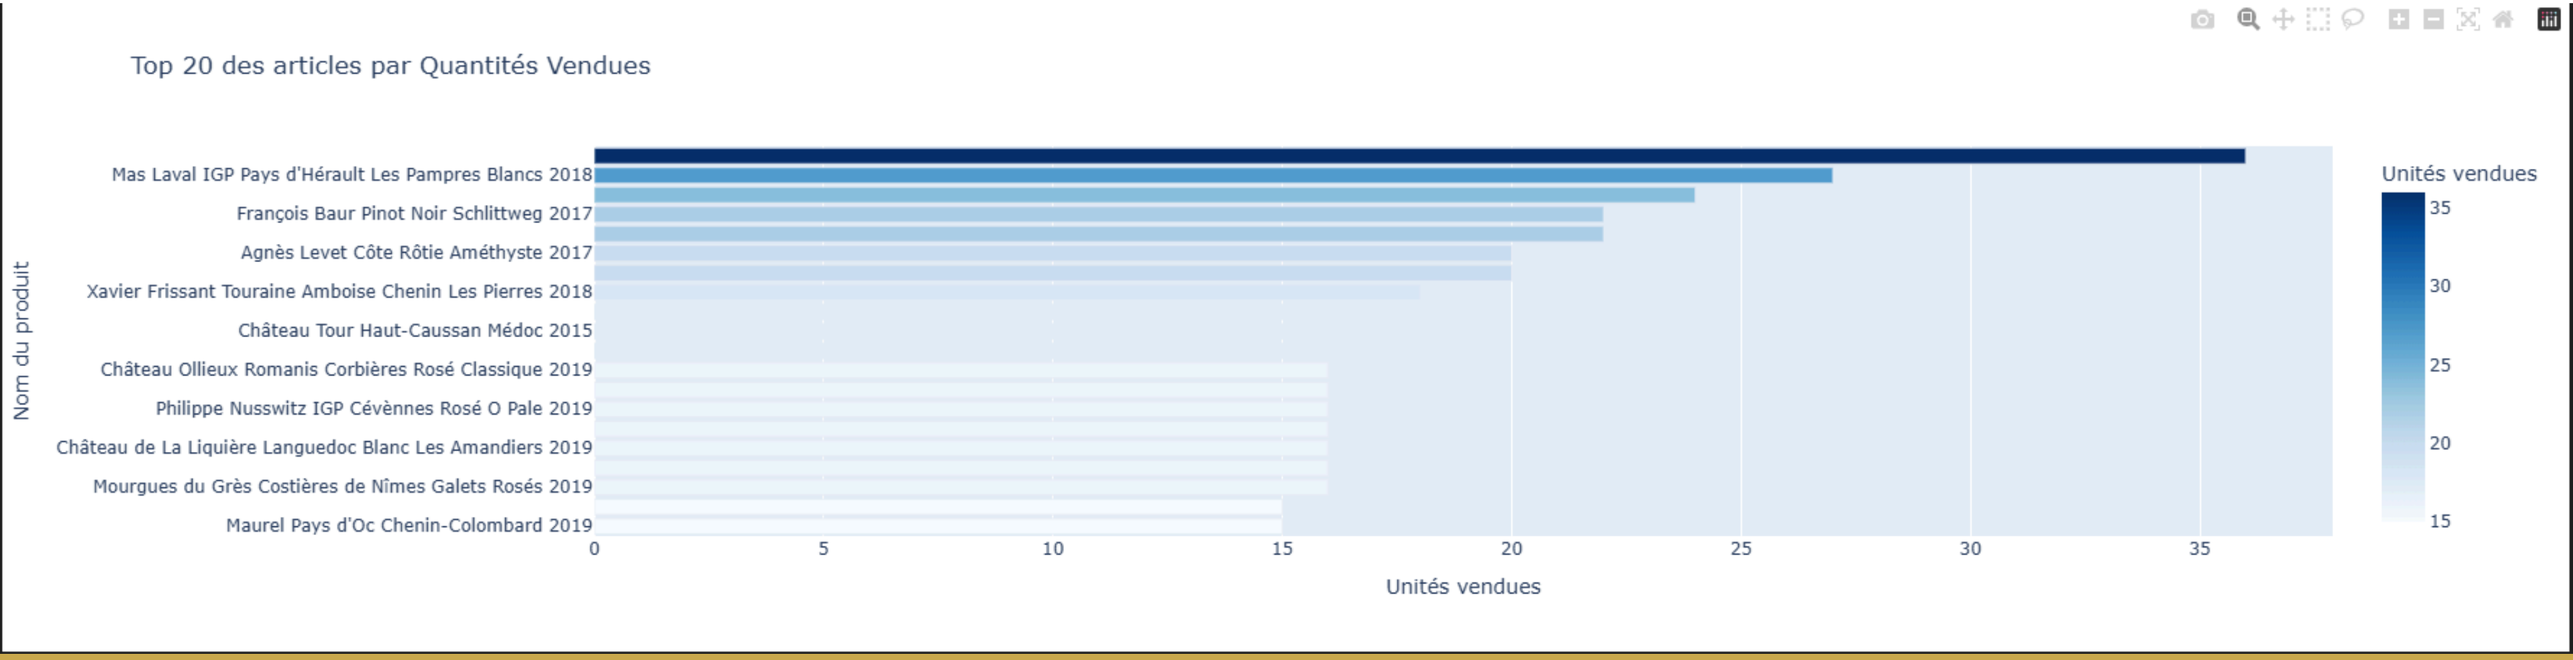

Bonus — Documentation

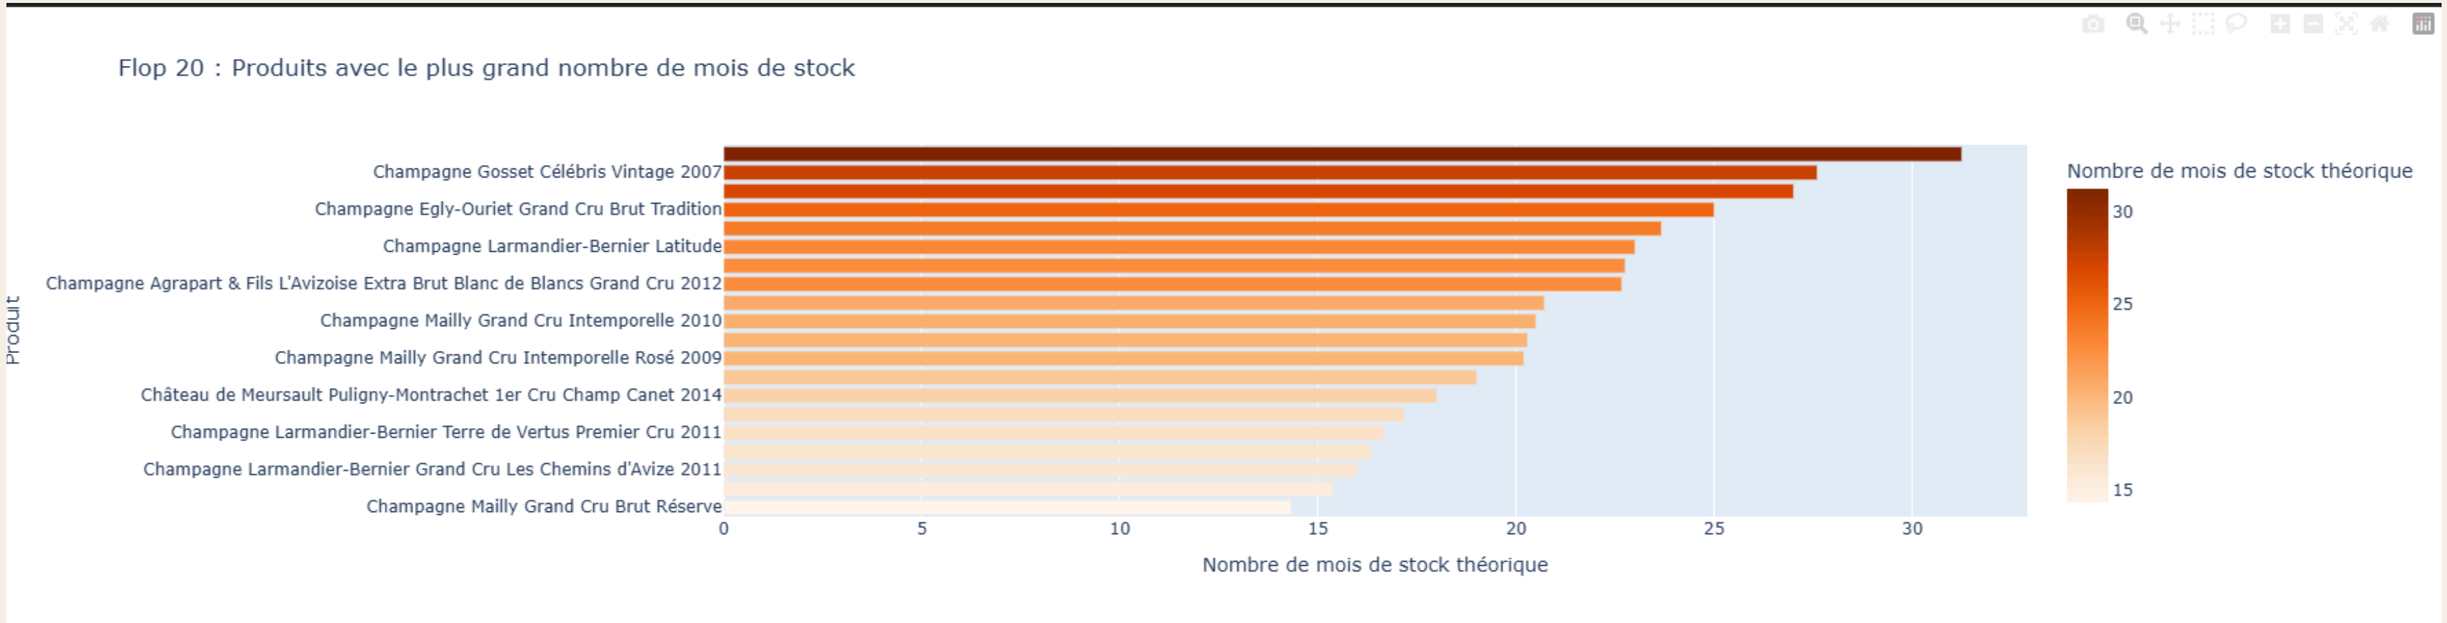

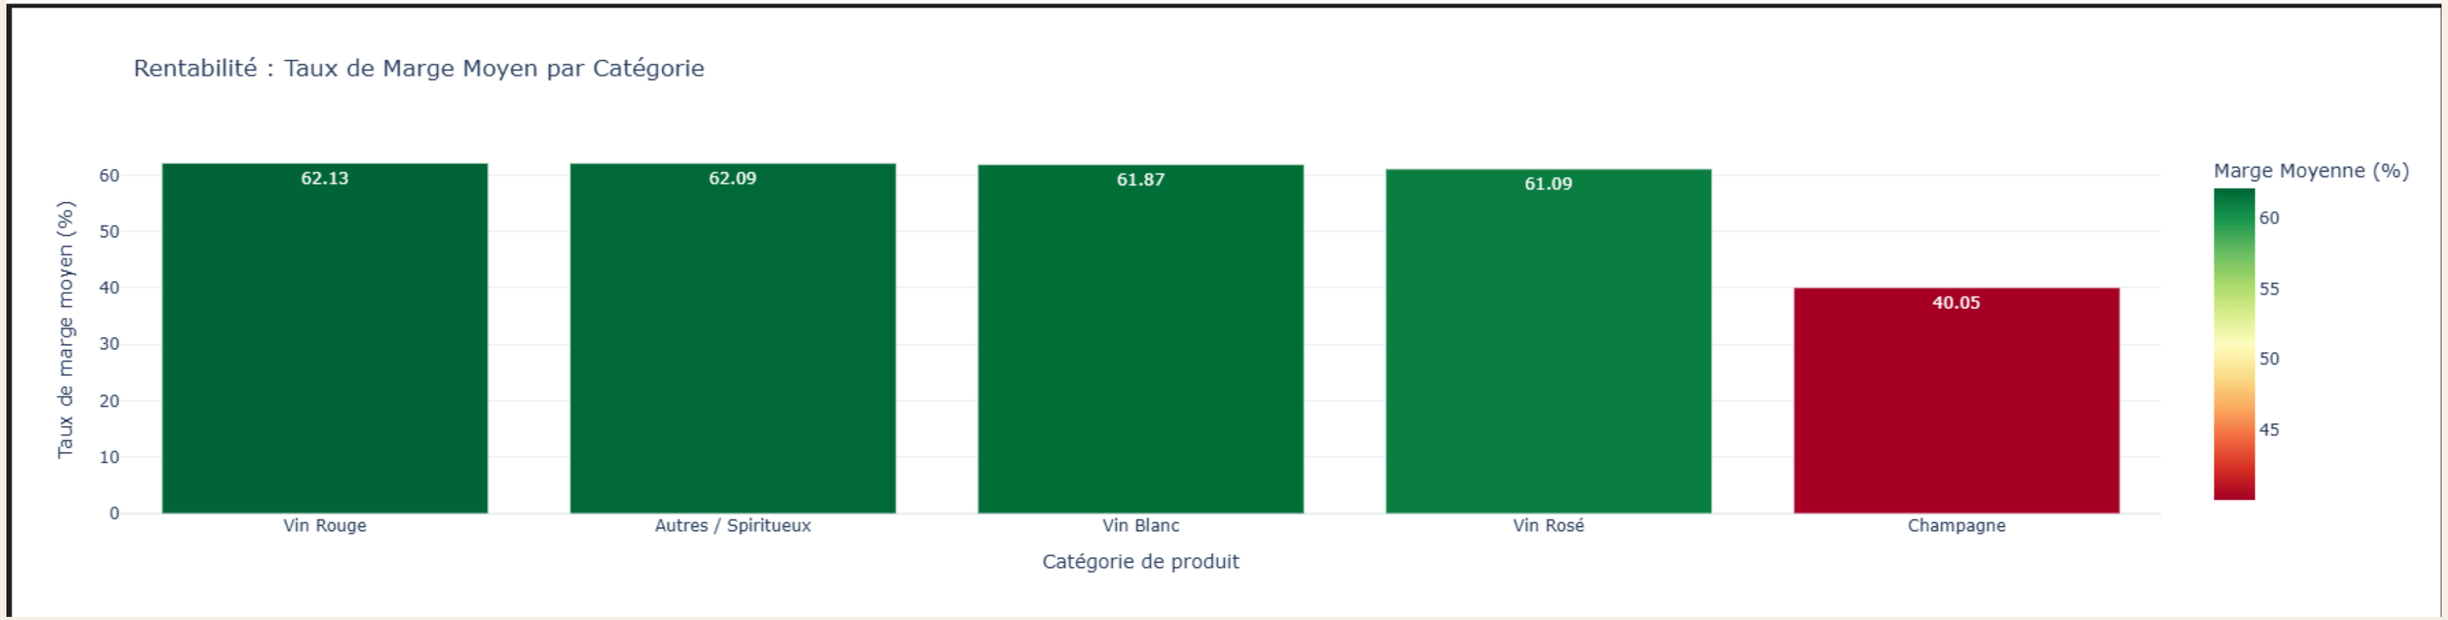

Bonus — Documentation

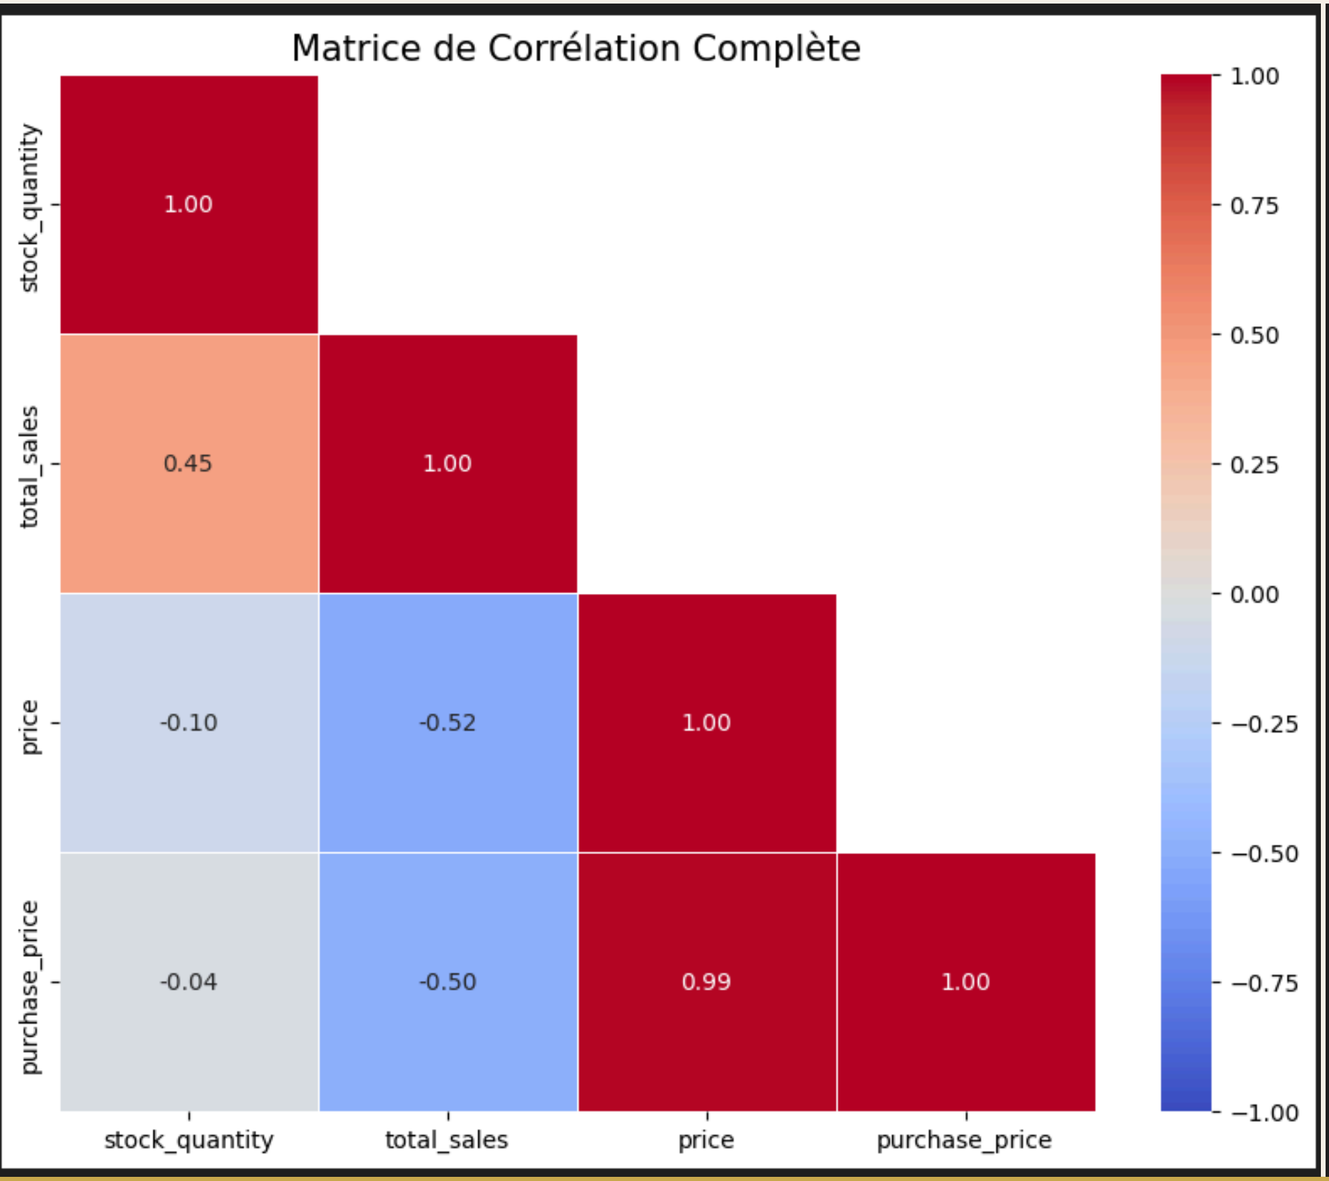

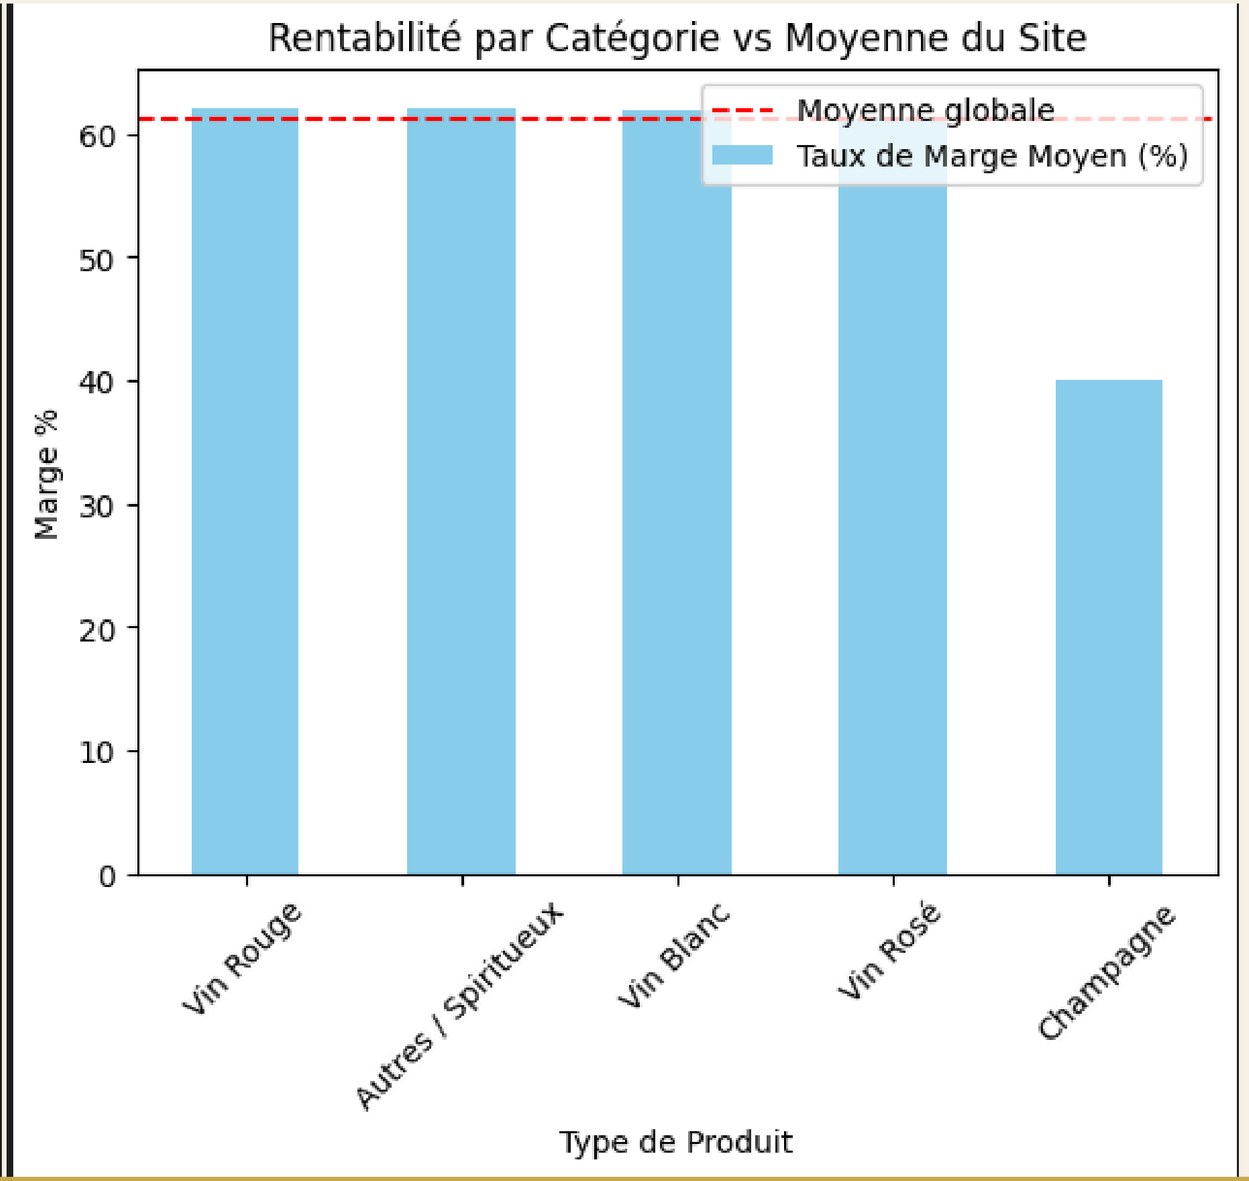

Bonus — Documentation

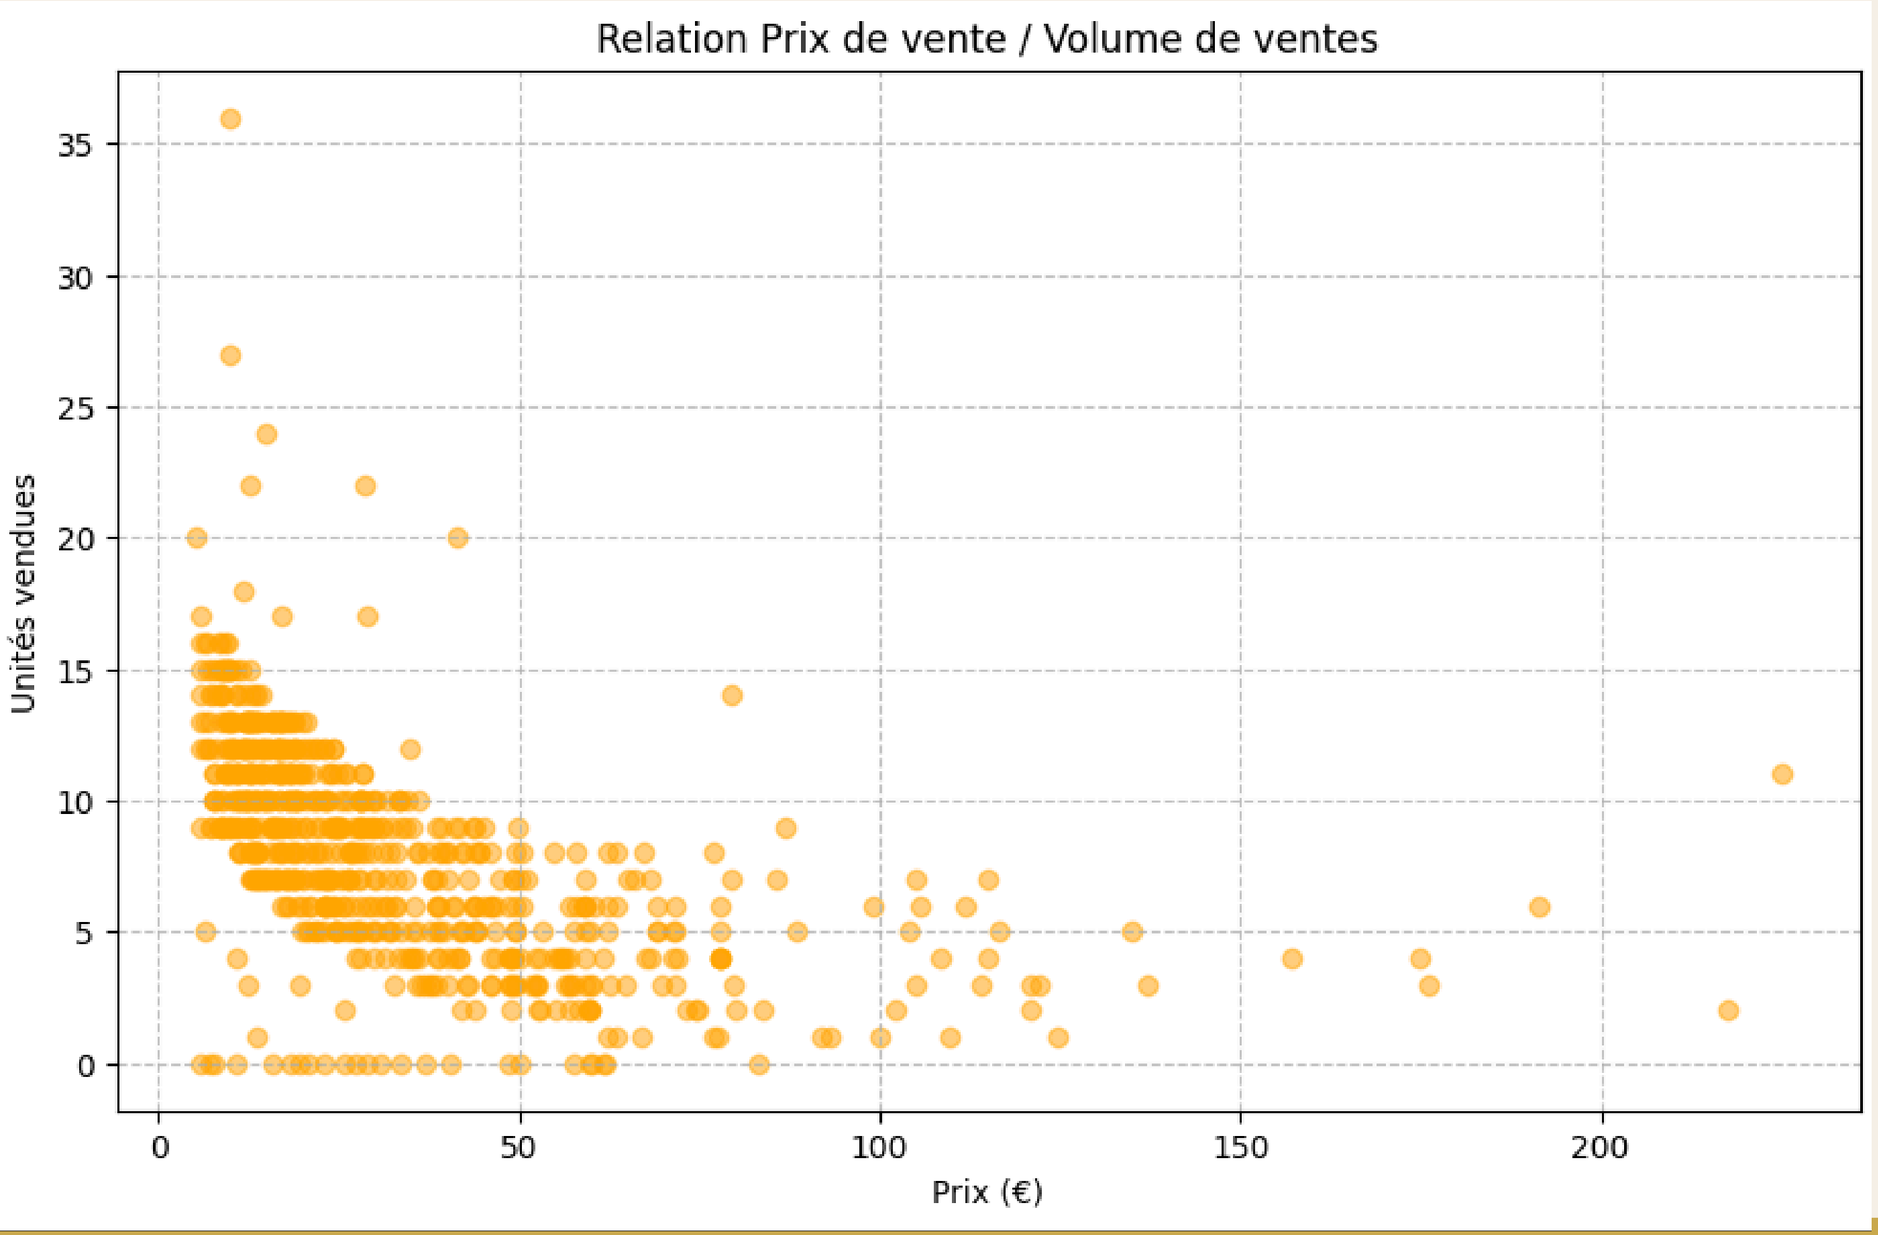

Coefficient de corrélation Prix/Ventes : -0.52